

Perceptronul

Printre primele chestii descoperite în AI. Se utilizează pentru probleme de clasificare binară în care clasele sunt linear separabile. Ce înseamnă clasificare: am niște puncte într-un spațiu n-dimensional (date prin coordonatele lor x_1, x_2, \dots, x_n) și trebuie să zic din ce categorie/clasă fac parte. Ce înseamnă linear separabil: pot să trag o dreaptă/plan/hiperplan care să separe complet cele 2 clase, una să fie "sub" și una "deasupra" liniei. Un perceptron pentru clasificare binară de puncte în 2D are 2 ponderi (w_1 și w_2) și un bias. Dacă ne uităm la formula de calcul a outputului avem: $y = w_1 * x_1 + w_2 * x_2 + \text{bias}$ (înainte de funcția de activare sigmoidă; să nu o uitați că outputul final este de fapt $\sigma(y)$). Acum dacă mergem în ecuația parametrică a unei drepte în plan, care este $a * x + b * y + c = 0$, facem corespondența: $a = w_1$, $b = w_2$, $c = \text{bias}$. Observăm că perceptronul pleacă cu o dreaptă arbitrară (w_1, w_2, bias random) și ajustează w_1, w_2, bias astfel încât dreapta să separe dacă nu chiar corect, atunci cât mai bine astfel încât să fie cât mai puține puncte clasificate incorect. w_1 și w_2 controlează "panta" dreptei și bias-ul este translația stânga-dreapta (sau intercept cum se mai cheamă). Mare grijă că există probleme care nu sunt linear separabile, cum ar fi XOR (sau exclusive). Musai să știți că asta e o formă de învățare supervizată, adică bag date, ieșe output, compar cu ce trebuia să dea (supervizat) și calculez o eroare ca fiind ce trebuia să dea minus ce mi-a dat, și cu asta merg înapoi și „pedepsesc” perceptronul.

ANN

Am zis că perceptronul nu se știe la chestii care nu sunt liniar separabile. Multă vreme AI-ul a stagnat, până unii s-or găsit să pună mai mulți perceptroni și să-i aranjeze în straturi. La un ANN basic, neuronii din stratul superior sunt conectați cu toți neuronii de strat inferior. Zicem superior și inferior pentru că informația „curge” de la input, către hidden și după către output. Asta se cheamă în primul rând feedforward (informația curge liniar de la input la output) și fully connected ca îi fiecare cu fiecare. La fel ca la perceptron, o să am o eroare la final și pedepsim prin backpropagation. Până la urmă, ANN-ul zice că bun nu putem găsi o dreaptă în 2D, dar ce-ar fi dacă am găsi o „dreaptă” în ND, care proiectată în 2D s-ar putea să fie o „stramba” dacă e să ne luăm după geometria Euclidiană.

Exemplu concret: avem de clasificat poze alb-negru cu cifre de la 0 la 9, cu dimensiunea pătrată de $8 * 8$. Cum traducem asta în termeni de input și output. Păi în primul rând, rețeaua are un strat de neuroni de input, noi avem o matrice, deci trebuie să-i facem flatten. A doua chestie, rețeaua lucrează cel mai bine cu valori în $[0, 1]$ – ca așa îi designul la funcția de activare (tangenta hiperbolică sau sigmoidă clasică). Cum trecem de la $[0, 255]$ la $[0, 1]$ (lucram cu pixeli și astia sunt tip de data byte). Împartim valorile pixelilor la 255. Formula generală este $x = (x - x_{\min}) / (x_{\max} - x_{\min})$. Bun, suntem gata cu inputul. La hidden puneti ceva gen număr neuroni input + număr neuroni output. La output e ultima schemă ca acolo aveți output categoric, adică ar trebui să fie un număr întreg de la 0 la 9. Codificăm cifrele cu one-hot encoding, adică cifra 4 devine vectorul $[0, 0, 0, 0, 1, 0, 0, 0, 0, 0]$. Cifra 8 devine $[0, 0, 0, 0, 0, 0, 0, 0, 1, 0]$. Cam așa e. La final nu o să vă iasă direct din rețea așa frumos, ci o să vă iasă $[0.12, 0.22, 0.37, \dots, \text{blablabla}]$. Predicția este indexul maximumului din vector.